
Projeto e Análise de Algoritmos

Prof. Dr. Ednaldo B. Pizzolato

RELAÇÃO ESPAÇO X TEMPO E PROGRAMAÇÃO DINÂMICA

Agenda

- Parte A – Relação Espaço x Tempo
 - Introdução
 - Algoritmo de ordenação
 - String matching
 - Algoritmo de Horspool
 - Algoritmo de Boyer-Moore (intro)
 - Hashing (intro)
 - B-Trees (intro)
- Parte B – Programação Dinâmica

INTRODUÇÃO

Introdução

- O principal conceito envolvido com esta técnica é a avaliação do que é mais crucial para o desenvolvimento do algoritmo: espaço ou tempo.
- Considere, por exemplo, uma situação em que calcular o resultado de uma função para diversos pontos é importante, mas ao mesmo tempo consome muito tempo. Se o tempo é importante, basta alocar mais espaço e armazenar os valores pré-calculados em uma tabela.

Introdução

- Isso, na verdade, já foi muito empregado no passado com a elaboração de livros com valores pré-calculados de determinadas funções matemáticas.
- O conceito geral da técnica envolve pré-processamento/otimização de uma entrada de dados e armazenamento de informações extras (como resultado do processamento) de forma a obter uma aceleração na resolução do problema. Anany Levitin chama isso de **melhoramento de entrada de dados**.

Introdução

- Dois tipos de algoritmos são estudados envolvendo este conceito:
 - ❑ Ordenação por contagem
 - ❑ Algoritmos de busca de palavras em textos

Introdução

- Dois tipos de algoritmos são estudados envolvendo este conceito:
 - ❑ Ordenação por contagem
 - ❑ Algoritmo de Horspool (string matching)
 - ❑ Algoritmo de Boyer-Moore (string matching)

Introdução

- Outro tipo de abordagem é o simples uso de espaço extra para facilitar o acesso rápido ou mais flexível aos dados. Anany Levitin chama isso de **pré-estruturação**.
- Esta estruturação (mais voltada para o acesso aos dados) pode ser notada em soluções envolvendo hashings e indexação com árvores B.

Introdução

- Há ainda uma terceira forma de se utilizar a técnica de espaço por tempo associada a **programação dinâmica**.
- Como abordado no capítulo 8 do livro “Introduction to the Design and Analysis of Algorithms – 3rd edition”, a programação dinâmica está associada a soluções de subproblemas que se inter-relacionam (overlap). A ideia é armazenar os resultados dos subproblemas em uma tabela e, a partir dela, obter a solução do problema geral.

ORDENAÇÃO POR CONTAGEM

Ordenação por contagem

- Uma forma bem simples de se ordenar um vetor é contar quantos elementos são menores que um determinado valor sendo avaliado. Se, por exemplo, detectar-se que existem 10 elementos menores que ele, então ele será o 11^o elemento do vetor. Basta, depois, copiar o elemento em um outro vetor, na posição correta (11 se começar do 1 ou 10 se começar do 0). O algoritmo é chamado Comparison-CountingSort.

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

para $i \leftarrow 0$ até $n-1$ faça

$\text{cont}[i] \leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

$\text{cont}[j] \leftarrow \text{cont}[j] + 1$

 senão

$\text{cont}[i] \leftarrow \text{cont}[i] + 1$

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{cont}[i]] \leftarrow A[i]$

retorna S

| A | Cont |
|----|------|
| 10 | 0 |
| 22 | 0 |
| 31 | 0 |
| 4 | 0 |
| 16 | 0 |
| 9 | 0 |
| 27 | 0 |
| 19 | 0 |
| 15 | 0 |

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

para $i \leftarrow 0$ até $n-1$ faça

$\text{cont}[i] \leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

$\text{cont}[j] \leftarrow \text{cont}[j] + 1$

 senão

$\text{cont}[i] \leftarrow \text{cont}[i] + 1$

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{cont}[i]] \leftarrow A[i]$

retorna S

$i \rightarrow$

$j \rightarrow$

| A | Cont |
|----|------|
| 10 | 0 |
| 22 | 0 |
| 31 | 0 |
| 4 | 0 |
| 16 | 0 |
| 9 | 0 |
| 27 | 0 |
| 19 | 0 |
| 15 | 0 |

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

para $i \leftarrow 0$ até $n-1$ faça

$\text{cont}[i] \leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

$\text{cont}[j] \leftarrow \text{cont}[j] + 1$

 senão

$\text{cont}[i] \leftarrow \text{cont}[i] + 1$

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{cont}[i]] \leftarrow A[i]$

retorna S

$i \rightarrow$

$j \rightarrow$

| A | Cont |
|----|------|
| 10 | 0 |
| 22 | 1 |
| 31 | 0 |
| 4 | 0 |
| 16 | 0 |
| 9 | 0 |
| 27 | 0 |
| 19 | 0 |
| 15 | 0 |

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

para $i \leftarrow 0$ até $n-1$ faça

$\text{cont}[i] \leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

$\text{cont}[j] \leftarrow \text{cont}[j] + 1$

 senão

$\text{cont}[i] \leftarrow \text{cont}[i] + 1$

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{cont}[i]] \leftarrow A[i]$

retorna S

| | A | Cont |
|-----------------|----|------|
| $i \rightarrow$ | 10 | 0 |
| | 22 | 1 |
| $j \rightarrow$ | 31 | 0 |
| | 4 | 0 |
| | 16 | 0 |
| | 9 | 0 |
| | 27 | 0 |
| | 19 | 0 |
| | 15 | 0 |

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

para $i \leftarrow 0$ até $n-1$ faça

$\text{cont}[i] \leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

$\text{cont}[j] \leftarrow \text{cont}[j] + 1$

 senão

$\text{cont}[i] \leftarrow \text{cont}[i] + 1$

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{cont}[i]] \leftarrow A[i]$

retorna S

| | A | Cont |
|-----------------|----|------|
| $i \rightarrow$ | 10 | 0 |
| | 22 | 1 |
| $j \rightarrow$ | 31 | 1 |
| | 4 | 0 |
| | 16 | 0 |
| | 9 | 0 |
| | 27 | 0 |
| | 19 | 0 |
| | 15 | 0 |

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

para $i \leftarrow 0$ até $n-1$ faça

$\text{cont}[i] \leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

$\text{cont}[j] \leftarrow \text{cont}[j] + 1$

 senão

$\text{cont}[i] \leftarrow \text{cont}[i] + 1$

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{cont}[i]] \leftarrow A[i]$

retorna S

| | A | Cont |
|-----------------|----|------|
| $i \rightarrow$ | 10 | 0 |
| | 22 | 1 |
| | 31 | 1 |
| $j \rightarrow$ | 4 | 0 |
| | 16 | 0 |
| | 9 | 0 |
| | 27 | 0 |
| | 19 | 0 |
| | 15 | 0 |

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

para $i \leftarrow 0$ até $n-1$ faça

$\text{cont}[i] \leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

$\text{cont}[j] \leftarrow \text{cont}[j] + 1$

 senão

$\text{cont}[i] \leftarrow \text{cont}[i] + 1$

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{cont}[i]] \leftarrow A[i]$

retorna S

$i \rightarrow$

$j \rightarrow$

| A | Cont |
|----|------|
| 10 | 1 |
| 22 | 1 |
| 31 | 1 |
| 4 | 0 |
| 16 | 0 |
| 9 | 0 |
| 27 | 0 |
| 19 | 0 |
| 15 | 0 |

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

para $i \leftarrow 0$ até $n-1$ faça

$\text{cont}[i] \leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

$\text{cont}[j] \leftarrow \text{cont}[j] + 1$

 senão

$\text{cont}[i] \leftarrow \text{cont}[i] + 1$

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{cont}[i]] \leftarrow A[i]$

retorna S

$i \rightarrow$

$j \rightarrow$

| A | Cont |
|----|------|
| 10 | 1 |
| 22 | 1 |
| 31 | 1 |
| 4 | 0 |
| 16 | 0 |
| 9 | 0 |
| 27 | 0 |
| 19 | 0 |
| 15 | 0 |

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

para $i \leftarrow 0$ até $n-1$ faça

$\text{cont}[i] \leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

$\text{cont}[j] \leftarrow \text{cont}[j] + 1$

 senão

$\text{cont}[i] \leftarrow \text{cont}[i] + 1$

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{cont}[i]] \leftarrow A[i]$

retorna S

$i \rightarrow$

$j \rightarrow$

| A | Cont |
|----|------|
| 10 | 1 |
| 22 | 1 |
| 31 | 1 |
| 4 | 0 |
| 16 | 1 |
| 9 | 0 |
| 27 | 0 |
| 19 | 0 |
| 15 | 0 |

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

para $i \leftarrow 0$ até $n-1$ faça

$\text{cont}[i] \leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

$\text{cont}[j] \leftarrow \text{cont}[j] + 1$

 senão

$\text{cont}[i] \leftarrow \text{cont}[i] + 1$

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{cont}[i]] \leftarrow A[i]$

retorna S

$i \rightarrow$

$j \rightarrow$

| A | Cont |
|----|------|
| 10 | 1 |
| 22 | 1 |
| 31 | 1 |
| 4 | 0 |
| 16 | 1 |
| 9 | 0 |
| 27 | 0 |
| 19 | 0 |
| 15 | 0 |

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

para $i \leftarrow 0$ até $n-1$ faça

$\text{cont}[i] \leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

$\text{cont}[j] \leftarrow \text{cont}[j] + 1$

 senão

$\text{cont}[i] \leftarrow \text{cont}[i] + 1$

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{cont}[i]] \leftarrow A[i]$

retorna S

$i \rightarrow$

$j \rightarrow$

| A | Cont |
|----|------|
| 10 | 2 |
| 22 | 1 |
| 31 | 1 |
| 4 | 0 |
| 16 | 1 |
| 9 | 0 |
| 27 | 0 |
| 19 | 0 |
| 15 | 0 |

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

para $i \leftarrow 0$ até $n-1$ faça

$\text{cont}[i] \leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

$\text{cont}[j] \leftarrow \text{cont}[j] + 1$

 senão

$\text{cont}[i] \leftarrow \text{cont}[i] + 1$

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{cont}[i]] \leftarrow A[i]$

retorna S

$i \rightarrow$

$j \rightarrow$

| A | Cont |
|----|------|
| 10 | 2 |
| 22 | 1 |
| 31 | 1 |
| 4 | 0 |
| 16 | 1 |
| 9 | 0 |
| 27 | 0 |
| 19 | 0 |
| 15 | 0 |

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

para $i \leftarrow 0$ até $n-1$ faça

$\text{cont}[i] \leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

$\text{cont}[j] \leftarrow \text{cont}[j] + 1$

 senão

$\text{cont}[i] \leftarrow \text{cont}[i] + 1$

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{cont}[i]] \leftarrow A[i]$

retorna S

$i \rightarrow$

$j \rightarrow$

| A | Cont |
|----|------|
| 10 | 2 |
| 22 | 1 |
| 31 | 1 |
| 4 | 0 |
| 16 | 1 |
| 9 | 0 |
| 27 | 1 |
| 19 | 0 |
| 15 | 0 |

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

para $i \leftarrow 0$ até $n-1$ faça

$\text{cont}[i] \leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

$\text{cont}[j] \leftarrow \text{cont}[j] + 1$

 senão

$\text{cont}[i] \leftarrow \text{cont}[i] + 1$

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{cont}[i]] \leftarrow A[i]$

retorna S

$i \rightarrow$

$j \rightarrow$

| A | Cont |
|----|------|
| 10 | 2 |
| 22 | 1 |
| 31 | 1 |
| 4 | 0 |
| 16 | 1 |
| 9 | 0 |
| 27 | 1 |
| 19 | 0 |
| 15 | 0 |

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

para $i \leftarrow 0$ até $n-1$ faça

$\text{cont}[i] \leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

$\text{cont}[j] \leftarrow \text{cont}[j] + 1$

 senão

$\text{cont}[i] \leftarrow \text{cont}[i] + 1$

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{cont}[i]] \leftarrow A[i]$

retorna S

$i \rightarrow$

$j \rightarrow$

| A | Cont |
|----|------|
| 10 | 2 |
| 22 | 1 |
| 31 | 1 |
| 4 | 0 |
| 16 | 1 |
| 9 | 0 |
| 27 | 1 |
| 19 | 1 |
| 15 | 0 |

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

para $i \leftarrow 0$ até $n-1$ faça

$\text{cont}[i] \leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

$\text{cont}[j] \leftarrow \text{cont}[j] + 1$

 senão

$\text{cont}[i] \leftarrow \text{cont}[i] + 1$

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{cont}[i]] \leftarrow A[i]$

retorna S

$i \rightarrow$

$j \rightarrow$

| A | Cont |
|----|------|
| 10 | 2 |
| 22 | 1 |
| 31 | 1 |
| 4 | 0 |
| 16 | 1 |
| 9 | 0 |
| 27 | 1 |
| 19 | 1 |
| 15 | 0 |

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

para $i \leftarrow 0$ até $n-1$ faça

$\text{cont}[i] \leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

$\text{cont}[j] \leftarrow \text{cont}[j] + 1$

 senão

$\text{cont}[i] \leftarrow \text{cont}[i] + 1$

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{cont}[i]] \leftarrow A[i]$

retorna S

$i \rightarrow$

$j \rightarrow$

| A | Cont |
|----|------|
| 10 | 2 |
| 22 | 1 |
| 31 | 1 |
| 4 | 0 |
| 16 | 1 |
| 9 | 0 |
| 27 | 1 |
| 19 | 1 |
| 15 | 1 |

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

para $i \leftarrow 0$ até $n-1$ faça

$\text{cont}[i] \leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

$\text{cont}[j] \leftarrow \text{cont}[j] + 1$

 senão

$\text{cont}[i] \leftarrow \text{cont}[i] + 1$

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{cont}[i]] \leftarrow A[i]$

retorna S

$i \rightarrow$

$j \rightarrow$

| A | Cont |
|----|------|
| 10 | 2 |
| 22 | 1 |
| 31 | 1 |
| 4 | 0 |
| 16 | 1 |
| 9 | 0 |
| 27 | 1 |
| 19 | 1 |
| 15 | 1 |

O que deu para descobrir até o momento?

Ordenação por contagem

ComparisonCountingSort($A[0..n-1]$)

Eficiência?

para $i \leftarrow 0$ até $n-1$ faça

 contador[i] $\leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

 para $j \leftarrow i+1$ até $n-1$ faça

 se $A[i] < A[j]$ então

 contador[j] \leftarrow contador[j] + 1

 senão

 contador[i] \leftarrow contador[i] + 1

para $i \leftarrow 0$ até $n-1$ faça

$S[\text{contador}[i]] \leftarrow A[i]$

retorna S

Ordenação por contagem

ComparisonCountingSort(A[0..n-1])

para $i \leftarrow 0$ até $n-1$ faça

contador[i] $\leftarrow 0$

para $i \leftarrow 0$ até $n-2$ faça

para $j \leftarrow i+1$ até $n-1$ faça

se $A[i] < A[j]$ então

contador[j] \leftarrow contador[j] + 1

senão

contador[i] \leftarrow contador[i] + 1

para $i \leftarrow 0$ até $n-1$ faça

S[contador[i]] $\leftarrow A[i]$

retorna S

Eficiência?

$$C(n) = \sum_{i=0}^{n-2} \sum_{j=i+1}^{n-1} 1 = \sum_{i=0}^{n-2} [(n-1) - (i+1) + 1]$$

$$= \sum_{i=0}^{n-2} (n-1+i) = \frac{n(n-1)}{2}$$

Ordenação por contagem

- Em resumo, o algoritmo faz o mesmo número de comparações que o algoritmo de seleção (SelectionSort) e, além disso, usa espaço extra.
- Por outro lado, o algoritmo faz as atribuições de forma cirúrgica.
- Uma variação deste algoritmo é o Distribution Counting (ver animação no ambiente virtual).

OTIMIZAÇÃO DE ENTRADA DE DADOS

Otimização de entrada de dados

Para ilustrar a utilidade da otimização (ou melhoramento) da entrada de dados, será utilizado o problema de string matching, ou seja, encontrar uma sequência (padrão) de m caracteres em um texto de n caracteres.

Considerando o algoritmo de força bruta que compara os caracteres da sequência buscada com os do texto um a um, teríamos, no pior caso, um algoritmo pertencente à classe $O(n.m)$. No caso médio, com textos em linguagem natural, espera-se que o algoritmo pertença à classe $O(n+m)$.

Otimização de entrada de dados

Só para ilustrar, vamos considerar o exemplo de busca por um padrão em uma sequência genética.


Uma **sequência de DNA** ou **sequência genética** é uma série de letras representando a estrutura primária de uma molécula ou cadeia de DNA, real ou hipotética, com a capacidade de carregar informações.

As letras possíveis são **A**, **C**, **G** e **T**, representando os quatro nucleotídeos (subunidades) de uma cadeia de DNA – as bases adenina, citosina, guanina e timina.

Otimização de entrada de dados

C G T A A A C G G G T A T T G


Deseja-se buscar a sequência
G T A T



Otimização de entrada de dados

C G T A A A C G G G T A T T G


G T A T



Otimização de entrada de dados

C G T A A A C G G G T A T T G


G T A T



Otimização de entrada de dados

C G T A A A C G G G T A T T G


G T A T



Otimização de entrada de dados

C G T A A A C G G G T A T T G


G T A T



Otimização de entrada de dados

C G T A A A C G G G T A T T G


G T A T



Otimização de entrada de dados

C G T A A A C G G G T A T T G


G T A T



Otimização de entrada de dados

C G T A A C G G G T A T T G


G T A T



Otimização de entrada de dados

C G T A A A C G G G T A T T G


G T A T



Otimização de entrada de dados

C G T A A A C G G G T A T T G


G T A T



Otimização de entrada de dados

C G T A A A C G G G T A T T G


G T A T



Otimização de entrada de dados

C G T **A** A C G G G T A T T G


G T A T



Otimização de entrada de dados

C G T A A A C G G G T A T T G


G T A T



Otimização de entrada de dados

C G T A A C G G G T A T T G


G T A T



Otimização de entrada de dados

C G T A A A C G G G T A T T G


G T A T



Otimização de entrada de dados

C G T A A **A** C G G G T A T T G


G T A T



Otimização de entrada de dados

C G T A A A C G G G T A T T G


G T A T



Otimização de entrada de dados

C G T A A A C G G G T A T T G


G T A T



Otimização de entrada de dados

C G T A A A C G G G T A T T G


G T A T



Otimização de entrada de dados

C G T A A A C **G** G G T A T T G


G T A T



Otimização de entrada de dados

C G T A A A C G G G T A T T G

G T A T



Otimização de entrada de dados

Diversos algoritmos mais eficientes que os de força bruta foram descobertos para resolver tal problema. A maioria utiliza a técnica de *melhoramento da entrada de dados*:

1. Pre-processar o padrão para se obter uma informação rele-vante;
2. Armazenar a informação em uma tabela;
3. Utilizar tal informação durante a busca pelo padrão em um texto.

Esta é a ideia de alguns algoritmos como os conhecidos: Horspool, Boyer-Moore e Knuth-Morris-Pratt (KMP)

Otimização de entrada de dados

■ Algoritmo de Horspool

Considere a busca do padrão BARBER em um texto:

$s_0, \dots, c, \dots, s_{n-1}$
BARBER

Começando com o último R do padrão e movendo da direita para a esquerda, são comparados pares de caracteres do padrão e do texto.

Se todos os caracteres do padrão combinarem, uma cadeia foi encontrada.

Otimização de entrada de dados

- Se ocorrer uma combinação mal sucedida, deve-se deslocar o padrão o **máximo possível** sem correr o risco de perder uma cadeia coincidente.
- A questão é identificar o **máximo possível** de tal forma que o risco de perder uma cadeia não exista.
- O algoritmo de Horspool determina o tamanho do deslocamento olhando para o caractere **c** do texto que foi alinhado com o último caractere padrão.

Otimização de entrada de dados

- Caso 1: Se não há **c** no padrão, pode-se deslocar o padrão pelo seu comprimento total.
- Caso 2: Caso existam ocorrências do caractere **c** no padrão, mas não é o último, o deslocamento deve alinhar a ocorrência mais a direita do padrão com o **c** do texto.
- Caso 3: Se acontecer de **c** ser o último caractere no padrão e não existirem outros **c**'s dentre os $m-1$ outros caracteres, o deslocamento deve ser similar ao caso 1.
- Caso 4: Pode acontecer de **c** ser o último caractere no padrão e também existirem outros **c**'s dentre os $m-1$ outros caracteres. Neste caso, o deslocamento deve ser similar ao caso 2.

Otimização de entrada de dados

- Estes exemplos demonstram que são possíveis deslocamentos maiores que 1 posição (como os feitos pelo algoritmo de força bruta).
- Entretanto, se o algoritmo tiver que verificar todos os caracteres do padrão a cada deslocamento, ele perderá sua eficiência.
- É aí que entra a ideia de melhoramento da entrada de dados para evitar comparações repetitivas desnecessárias.

Algoritmo de Horspool

- Pode-se pre-calcular tamanhos de deslocamentos e armazená-los em uma tabela.
- A tabela será indexada por todos os caracteres possíveis que possam ser encontrados em um texto, incluindo pontuação, espaço e outros símbolos especiais.
- A tabela será preenchida com tamanho de deslocamentos.

Algoritmo de Horspool

- Para cada caractere c podemos calcular o valor do deslocamento pela fórmula:

Se c não estiver dentre os $m-1$ primeiros caracteres do padrão, então

$t(c) = \text{comprimento } m \text{ do padrão}$

Caso contrário

$t(c) = \text{distância do } c \text{ mais a direita dentre os } m-1 \text{ caracteres do padrão e seu último caractere}$

Por exemplo, para o padrão BARBER, todas as entradas da tabela serão iguais a 6, exceto as entradas correspondentes a A, B, E e R que serão 4, 2, 1 e 3 respectivamente.

Algoritmo de Horspool

Algoritmo ShiftTable($P[0..m-1]$)

for $i \leftarrow 0$ até $TAM-1$ faça

$tabela[i] \leftarrow m$

for $j \leftarrow 0$ até $m-2$ faça

$tabela[P[j]] \leftarrow m - 1 - j$

Retorna tabela

Onde TAM indica o número máximo de caracteres do alfabeto em questão.

| Letra | Desloca |
|-------|---------|
| A | 4 |
| B | 2 |
| C | 6 |
| D | 6 |
| E | 1 |
| F | 6 |
| G | 6 |
| H | 6 |
| I | 6 |
| ... | 6 |
| R | 3 |
| ... | 6 |

BARBER

Algoritmo de Horspool

- Passo 1: Para um dado padrão de comprimento m e o alfabeto usado tanto no padrão como no texto, construir a tabela de deslocamentos;
- Passo 2: Alinhar o padrão como começo do texto;
- Passo 3: Repetir até encontrar uma *substring* coincidente ou o padrão atingir o último caractere do texto.

Algoritmo de Horspool

- Passo 3 (continuação):
 - ❑ Começando pelo último caractere do padrão, comparar os caracteres correspondentes no padrão e no texto até que todos os m caracteres coincidam ou até que ocorra uma combinação mal sucedida;
 - ❑ No caso de combinação mal sucedida, ler a entrada $t(c)$ da coluna c da tabela de deslocamentos, onde c é o caractere do texto sendo alinhado com o último caractere do padrão;
 - ❑ Deslocar o padrão $t(c)$ caracteres a direita.

Algoritmo de Horspool

HorspoolMatching(P[0..m-1], T[0..n-1])

ShiftTable(P[0..m-1]) // cria a tabela de deslocamentos

$i \leftarrow m - 1$ // POSIÇÃO DO ÚLTIMO CARACTERE DO PADRÃO

enquanto $i \leq n - 1$ faça // ENQUANTO NÃO SE ATINGIR FIM DO TEXTO

$k \leftarrow 0$ // NÚMERO DE CARACTERES IDÊNTICOS

enquanto $k \leq m - 1$ E $P[m-1-k] = T[i-k]$ faça

$k \leftarrow k + 1$

se $k = m$ então retorna $i - m + 1$ // ACHOU !!!

senão $i \leftarrow i + \text{Tabela}[T[i]]$ // AQUI OCORRE O DESLOCAMENTO

retorna -1

Algoritmo de Horspool - exemplo

- Buscar a palavra BARBER em um texto:

| letra | A | B | C | D | E | ... | R | ... | Z | - | ... |
|-------|---|---|---|---|---|-----|---|-----|---|---|-----|
| Shift | 4 | 2 | 6 | 6 | 1 | 6 | 3 | 6 | 6 | 6 | 6 |

| | | | | | | | | | | | | | | | | | | | | | | | | | |
|---|---|---|---|---|---|---|--|---|---|--|---|---|--|---|--|---|---|---|---|---|---|---|---|---|---|
| J | I | M | | S | A | W | | M | E | | I | N | | A | | B | A | R | B | E | R | S | H | O | P |
| B | A | R | B | E | R | | | | | | | | | | | | | | | | | | | | |

```
i ← m - 1           // NOSSO CASO I ← 5
k ← 0                // NÚMERO DE CARACTERES IDÊNTICOS
enquanto k ≤ m - 1 E P[m-1-k] = T[i-k] faça
    k ← k + 1
se k = m então retorna i - m + 1
senão i ← i + Tabela[T[i]]
```

Algoritmo de Horspool - exemplo

- Buscar a palavra BARBER em um texto:

| letra | A | B | C | D | E | ... | R | ... | Z | - | ... |
|-------|---|---|---|---|---|-----|---|-----|---|---|-----|
| Shift | 4 | 2 | 6 | 6 | 1 | 6 | 3 | 6 | 6 | 6 | 6 |

| | | | | | | | | | | | | | | | | | | | | | | | | | |
|---|---|---|---|---|---|---|--|---|---|--|---|---|--|---|--|---|---|---|---|---|---|---|---|---|---|
| J | I | M | | S | A | W | | M | E | | I | N | | A | | B | A | R | B | E | R | S | H | O | P |
| B | A | R | B | E | R | | | | | | | | | | | | | | | | | | | | |

```
i ← m - 1           // NOSSO CASO I ← 5
k ← 0               // NÚMERO DE CARACTERES IDÊNTICOS
enquanto k ≤ m - 1 E P[m-1-k] = T[i-k] faça
    k ← k + 1
se k = m então retorna i - m + 1
senão i ← i + Tabela[T[i]]
```

Algoritmo de Horspool - exemplo

- Buscar a palavra BARBER em um texto:

| letra | A | B | C | D | E | ... | R | ... | Z | - | ... |
|-------|---|---|---|---|---|-----|---|-----|---|---|-----|
| Shift | 4 | 2 | 6 | 6 | 1 | 6 | 3 | 6 | 6 | 6 | 6 |

[illegible]

```

i ← m - 1 // NOSSO CASO I ← 5
k ← 0 // NÚMERO DE CARACTERES IDÊNTICOS
enquanto k ≤ m - 1 E P[m - 1 - k] = T[i - k] faça
    k ← k + 1
se k = m então retorna i - m + 1
senão i ← i + Tabela[T[i]]

```

Algoritmo de Horspool - exemplo

- Buscar a palavra BARBER em um texto:

| letra | A | B | C | D | E | ... | R | ... | Z | - | ... |
|-------|---|---|---|---|---|-----|---|-----|---|---|-----|
| Shift | 4 | 2 | 6 | 6 | 1 | 6 | 3 | 6 | 6 | 6 | 6 |

[illegible]

```

i ← m - 1 // NOSSO CASO I ← 5
k ← 0 // NÚMERO DE CARACTERES IDÊNTICOS
enquanto k ≤ m - 1 E P[m-1-k] = T[i-k] faça
    k ← k + 1
se k = m então retorna i - m + 1
senão i ← i + Tabela[T[i]]

```


Algoritmo de Horspool - exemplo

- Buscar a palavra BARBER em um texto:

| letra | A | B | C | D | E | ... | R | ... | Z | - | ... |
|-------|---|---|---|---|---|-----|---|-----|---|---|-----|
| Shift | 4 | 2 | 6 | 6 | 1 | 6 | 3 | 6 | 6 | 6 | 6 |

| J | I | M | | S | A | W | | M | E | | I | N | | A | | B | A | R | B | E | R | S | H | O | P |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| B | A | R | B | E | R | | | | | | | | | | | | | | | | | | | | |
| | | | | B | A | R | B | E | R | | | | | | | | | | | | | | | | |
| | | | | | B | A | R | B | E | R | | | | | | | | | | | | | | | |
| | | | | | | | | | | | B | A | R | B | E | R | | | | | | | | | |
| | | | | | | | | | | | | | B | A | R | B | E | R | | | | | | | |
| | | | | | | | | | | | | | | | | B | A | R | B | E | R | | | | |

Algoritmo de Horspool

- A eficiência no pior caso é $O(n.m)$
- Para textos aleatórios, a eficiência é $\Theta(n)$
- Na média, o algoritmo é mais rápido que o de força bruta.

Otimização de entrada de dados

■ Algoritmo Boyer-Moore

Se a comparação do caractere mais a direita do padrão com o caractere correspondente **c** no texto falhar, o algoritmo faz a mesma coisa que o algoritmo Horspool, ou seja, desloca o padrão a direita pelo número de caracteres pre-calculados (armazenados na tabela).

Se houver um número k ($k > 0$ e $k < m$) de comparações bem sucedidas, aí é que aparece a diferença entre os algoritmos.

Otimização de entrada de dados

- Nesta situação, o algoritmo B-M determina o tamanho do deslocamento considerando duas quantidades:
 - ❑ Deslocamento pelo símbolo incorreto (bad-symbol shift);
 - ❑ Deslocamento pelo bom sufixo (good-suffix shift)

PRE-ESTRUTURAÇÃO

Hashing

- A técnica Hashing baseia-se na ideia de distribuir chaves entre um arranjo unidimensional $H[0... M-1]$ chamado de tabela hash.
- A distribuição é feita calculando-se para cada uma das chaves o valor de alguma função pré-definida h , chamada de função hash.
- Esta função atribui um inteiro entre 0 e $m-1$, chamado de endereço hash para uma chave.

Hashing

- Por exemplo, se as chaves forem inteiros não negativos, uma função hash pode ser da forma:

$$h(K) = K \bmod m$$

Se as chaves forem letras do alfabeto, podemos inicialmente atribuir a uma letra sua posição no alfabeto indicado por $\text{ord}(K)$ e aplicar a mesma função hash.

Hashing

- Alguém pode perguntar como teríamos que proceder se as chaves fossem cadeias de caracteres (strings).
- Para strings de tamanho s , poder-se-ia utilizar, por exemplo, a fórmula a seguir:

$$\left(\sum_{i=0}^{s-1} \text{ord}(c_i) \right) \bmod m$$

Hashing


- Uma função Hash deve satisfazer dois requisitos:
 - ❑ Deve distribuir as chaves entre as células da tabela de uma maneira tão justa quanto possível;
 - ❑ Uma função hash deve ser fácil de calcular

Se escolhermos uma tabela hash de tamanho m (m menor que o número de chaves – n), existirão colisões.

Hashing

- Como colisões podem ocorrer, é necessário que existam mecanismos que resolvam tal problema.
- Em hashing temos o open hashing e o closed hashing.


Árvores B



- A ideia de utilizar espaço extra para facilitar rápido acesso a uma determinada informação é particularmente importante quando se trata de uma quantidade muito grande de dados.
- Os índices fornecem informações sobre a localização dos registros segundo uma chave de acesso.
- Claro que podem existir várias chaves de acesso e, portanto, vários índices.

Árvores B

- Uma das formas de se organizar um índice é através de árvores B.



Árvores B

- Uma árvore B de ordem $m \geq 2$ deve satisfazer as seguintes propriedades estruturais:
 - ❑ A raiz ou é uma folha ou tem entre 2 e m filhos;
 - ❑ Cada nó, exceto a raiz e as folhas tem entre $\lceil m/2 \rceil$ e m filhos (e, portanto, entre $\lceil m/2 \rceil - 1$ e $m - 1$ chaves);
 - ❑ A árvore é perfeitamente balanceada, ou seja, suas folhas estão todas no mesmo nível.

RESUMO

Resumo

- O uso de espaço extra para “ganhar tempo” ou de tempo extra para “economizar espaço” é um conceito amplamente conhecido e estudado por cientistas teóricos e práticos.
- O mais comum é o uso de espaço extra para “ganhar tempo” de execução/processamento.
- Dentro das variedades da técnica, a de otimização de entrada é a que objetiva pré-processar os dados de entrada de forma a acelerar o algoritmo posteriormente.

Resumo

- Os algoritmos de Horspool e de Boyer-Moore são exemplos de melhoramento da entrada de dados com o objetivo de obter melhor desempenho (tempo) do algoritmo.
- Pré-estruturação é outra variação da técnica que explora a troca de espaço por tempo que explora o conceito de uso de memória extra para melhoria do desempenho (tempo). Hashing e árvores B+ são 2 importantes exemplos.

Resumo

- Por fim duas considerações importantes:
 - ❑ Nem sempre é necessário “sacrificar” memória para se obter melhor desempenho. Vários algoritmos podem ser desenvolvidos com uso eficiente de memória e ao mesmo tempo conseguem apresentar desempenhos elevados;
 - ❑ A técnica desconsidera o uso de técnicas de compressão de dados. Seria possível combinar técnicas – em algumas situações – para se obter algoritmos eficientes tanto do ponto de vista de espaço como de tempo.



THE END