Universidade Federal de São Carlos Departamento de Computação

Sistemas Operacionais 2

2012/1

Hélio Crestana Guardia

http://www.dc.ufscar.br/~helio/so2

Objetivos

- Os alunos deverão conhecer, através de estudo de casos, questões relacionadas à **programação** em Sistemas Operacionais. Abordar o acesso aos **serviços** oferecidos em sistemas compartilhados e com múltiplos processadores e estudar suas **implementações**.
- Assim, enquanto a disciplina Sistemas Operacionais 1 trata dos aspectos da implementação dos mecanismos de gerenciamento dos recursos disponíveis, **Sistemas Operacionais 2** concentra-se em:
 - Estudar como o SO implementa suas políticas
 - Estudar quais recursos são oferecidos pelo SO para os programas
 - Conhecer técnicas para criação de programas que usam de maneira eficiente os recursos do SO, tanto em ambientes com memória compartilhada quanto naqueles com comunicação por passagem de mensagem.

Ementa

- Chamadas de sistema
- Serviços de entrada e saída
- Gerenciamento de processos e threads
- Comunicação e sincronização com memória compartilhada (IPC)
- Programação distribuída: passagem de mensagem, sincronização e execução remota de código
- Programação paralela: tarefas, comunicação e sincronização
- Algoritmos de programação paralela

Sistemas Operacionais 2 Hélio Crestana Guardia

Bibliografia

Conceitos

- Deitel, H.M.; Deitel, P.J. and Choffnes, D.R. Sistemas Operacionais. 3a edição. Pearson, 2005.
- Tanembaum, A. S. Sistemas Operacionais: Projeto e Implementação. 3a edição. Bookman, 2008.
- Andrews, G. R. Foundations of Multithreaded, Parallel, and Distributed Programming. Addison-Wesley, 2000.
- Tanembaum, A. S. Sistemas Operacionais Modernos. 3a edição, Pearson Pentice Hall, 2010.
- Wilkinson, B. and Allen, M. *Parallel Programming: Techniques and Applications Using Networked Workdstations and Parallel Computers*. Pearson Prentice Hall, 2005.
- Foster, I. Designing and Building Parallel Programs. MIT Press 1999. www-unix.mcs.anl.gov/dbpp.
- Bach, M. J. The Design of the Unix Operating System. Prentice-Hall, 1986.

Programação

- Mitchell, M.; Oldham, J.; and Samuel *Advanced Linux Programming* New Riders Publishing, 2001.
- Kernighan, B.W. *The Unix Programming Environment*. Prentice-Hall, 1984.
- Rochkind, M.J. Advanced Unix Programming. Prentice-Hall, 1985.
- Stevens, W. R. *Unix Network Programming: Interprocess Communications*. 2nd ed. Prentice Hall, 1999.
- Stevens, W. R. Unix Network Programming: Networking APIs: Sockets and XTI, 2nd ed. Prentice Hall, 1999.
- Snir, M. et. al. MPI The Complete Reference. Vol.1 The MPI Core. MIT, 1998, Second Edition.
- Gropp, W. e. al. MPI The Complete Reference. Vol.2 The MPI Extensions. MIT, 1998, Second Edition.
- Robbins, K. A. and Robbins, S. *Practical Unix Programming: A Guide to Concurrency, Communication, and Multithreading*. Prentice-Hall, 1996.

Sistema Operacional

Funções:

- Gerente de recursos
- Máquina virtual mais fácil de usar e programar
- Interface entre os usuários, e seus programas, e os recursos disponíveis

Aspectos de interesse:

- Hardware (processadores e elementos funcionais)
- Estratégias de implementação (arquitetura)
- Políticas e serviços oferecidos (syscalls)

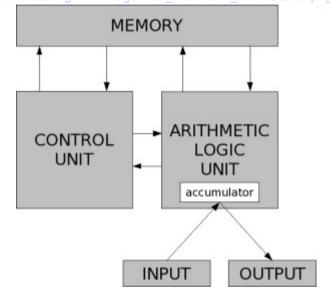
Sistemas Operacionais 2 Hélio Crestana Guardia

SO: hardware = recursos

http://commons.wikimedia.org/wiki/Image:Von_Neumann_architecture.pn

Arquitetura de Von Neumann:

- Programa = sequência de instruções na memória
- Registrador (**PC**) indica palavra de memória que contém próxima instrução a executar
- Decodificação e execução das instruções feitas a partir de um registrador interno da CPU (IR)



Operação:

```
Loop {
    IR = Mem[PC]
    PC = PC +1
    Executa IR
    Testa e trata INT
}
```

Busca instrução; uso do cache e mecanismos de prefetching, branch prediction, ...

Incrementa ponteiro de instruções. Incremento equivalente ao tamanho da palavra...

Decodifica e executa instrução. Lógica no nível de micro-programa.

Verifica interrupção: assíncrona (externa), trap, instrução (int)

SO: hardware = recursos

- Controladores de dispositivos (canais) com capacidade de operação independente
- Interconexão de controladores de dispositivos (barramentos):
 - Dados
 - Endereçamento
 - Controle
- Leitura e escrita entre dispositivos e memória:
 - Passando pela CPU (instruções in e out)
 - Usando DMA
- Detecção de alterações de estado dos controladores:
 - Polling (consulta pelo SO via barramento
 - Notificações assíncronas via interrupções
- Interrupções:
 - Externas
 - Traps
 - Instrução (int)

SO: Estratégias

- Entidades "escalonáveis": processos e threads
 - Representação de processos
 - Estados dos processos
 - Trocas de contexto
- Compartilhamento do processador:
 - Multiprogramação: sobreposição de Entrada e Saída (disco e rede) com execução de instruções
 - Fatias de tempo: interrupções periódicas
- Concorrência: ambientes monoprocessados
- Paralelismo: SMP, Multicore, HTT (Hyper Threading Technology), ou outras arquiteturas multiprocessadas.

SO: Serviços (System Calls)

- Todo **sistema operacional** provê uma **interface** para que programas solicitem **serviços** do núcleo.
- Variações de Unix oferecem funções bem definidas, chamadas *system calls*, ou **chamadas de sistema**.
- Definição das chamadas feita em C, independentemente do mecanismo utilizado para solicitação dos serviços.
- Cada chamada de sistema normalmente tem uma função com o mesmo nome definida em **C**.
- Processo de usuário chama função usando a sequência de chamada normal da linguagem.
- Função faz chamada apropriada ao serviço do *kernel*, colocando valores nos **registradores do** *hardware* (e possivelmente também na **pilha**) e chamando instrução de **interrupção**.

SO: Serviços (System Calls)

llseek(2), newselect(2), sysctl(2), accept(2), accept(2), acct(2), adjtimex(2), afs syscall, alarm(2), bdflush(2). $\overline{bind(2)}$, break, brk(2), cacheflush(2), capget(2), capset(2), chdir(2), chmod(2), chown(2), chown(3), clone(2), close(2), connect(2), creat(2), create module(2), delete module(2), dup(2), dup(2), execve(2), exit(2), fchdir(2), fchmod(2), fchown(2), fchown32, fcntl(2), fcntl64, fdata-sync(2), flock(2), fork(2), fstat(2), fstat64, fstatfs(2), fsync(2), ftime, ftruncate(2), ftruncate(64, get kernel syms(2), getcwd(2), getdents(2), getdents(4, getegid(2), getegid32, geteuid(2), geteuid32, getgid(2), getgid $\overline{3}$ 2, getgroups(2), getgroups32, getitimer(2), getpagesize(2), getpeername(2), getpmsg, getpgid(2), getpgrp(2), getpid(2), getppid(2), getpriority(2), getresgid(2)), getresgid32, getresuid(2), getresuid32, getrlimit(2), getrusage(2), getsid(2), getsockname(2), getsockopt(2), gettid, gettimeofday(2), getuid(2), getuid(32, gtty, idle, init module(2), ioctl(2), ioperm(2), iopl(2), ipc(2), kill(2), lchown(2), lchown32, link(2), listen(2), lock, lseek(2), lstat(2), lstat(4, madvise(2), mincore(2), mkdir(2), mknod(2), mlock(2), mlockall(2), mmap(2), modify ldt(2), mount(2), mpx, mpx, mremap(2), msync(2), munlock(2), munlockall(2), munmap(2), nanosleep(2), nfsservctl(2), nice(2), oldfstat, oldlstat, oldolduname, oldstat, oldumount, olduname, open(2), pause(2), personality(2), phys, **pipe(2**), pivot root(2), poll(2), prctl(2), pread(2), prof, profil, ptrace(2), putpmsg, pwrite(2), query module(2), quotactl(2), read(2), readahead, readdir(2), readlink(2), readv(2), reboot(2), recv(2), recvfrom(2), recvmsg(2), rename(2), rmdir(2), rt sigaction, rt sigpending, rt sigprocmask, rt sigqueueinfo, rt sigreturn, rt sigsuspend, rt sigtimedwait, sched get priority max(2), sched get priority min(2), sched getparam(2), sched getscheduler(2), sched rr get interval(2), sched setparam(2), sched setscheduler(2), sched yield(2), security, select(2), sendfile(2), send(2), sendmsg(2), sendto(2), setdomainname(2), setfsgid(2), setfsgid32, setfsuid(2), setfsuid32, setgid(2), setgid32, setgroups(2), setgroups32, sethostname(2), setitimer(2), setpgid(2), setpriority(2), setregid(2), setregid32, setresgid(2), setresgid32, setresuid(2), setresuid32, setreuid(2), setreuid32, setrelimit(2), setsid(2), setsockopt(2), settimeofday(2), setuid(2), setuid(32, setup(2), sgetmask(2), shutdown(2), sigaction(2), sigaltstack(2), signal(2), sigpending(2), sigprocmask(2), sigreturn(2), sigsuspend(2), socket(2), socketcall(2), socketpair(2), ssetmask(2), stat(2), stat(4, statfs(2), stime(2), stty, swapoff(2), swapon(2), symlink(2), sync(2), sysfs(2), sysinfo(2), syslog(2), time(2), times(2), truncate(2), truncate(4), ulimit, umask(2), umount(2), uname(2), unlink(2), uselib(2), ustat(2), utime(2), vfork(2), vhangup(2), vm86(2), vm86old, wait4(2), waitpid(2), **write(2)**, writev(2).

Hélio Crestana Guardia

Como usar os recursos computacionais de maneira eficiente?

- Exploração (via serviços do SO) dos múltiplos **elementos** funcionais **autônomos** do hardware (canais de E/S e processadores) implica organizar o *software* a ser executado para conter **partes** relativamente **independentes**.
- Modelos de aplicações que exploram o paralelismo:
 - Aplicações multi-threaded
 - Aplicações distribuídas
 - Aplicações paralelas

Modelos de aplicação

- *Software multithread* gerencia múltiplas atividades independentes, tais como sistemas de janelas em computadores pessoais ou *workstations*, sistemas de tempo-real que controlam ambientes externos, etc.
- Exemplos de computação distribuída incluem sistemas de arquivo em um sistema em rede, bancos de dados para sistemas bancários, venda de passagens aéreas, servidores web na Internet, etc.
- Exemplos de **computação paralela** incluem computação científica que modela e simula fenômenos climáticos, bioinformática, como na análise do efeito de novas drogas, processamento gráfico e de imagens, incluindo a criação de efeitos especiais em filmes, grandes problemas combinatoriais ou de otimização, etc.

O grau de **dependência** e a forma de **interconexão** dos processadores são importantes no suporte ao **modelo de programação** selecionado.

Modelos de programação

Programação com Memória Compartilhada:

- *Threads*: programas são decompostos em sequências paralelas (*threads*), que compartilham variáveis dentro do escopo do programa.
 - *Pthreads*: biblioteca padronizada para manipulação de *threads*
- Programas escritos em linguagem de programação sequencial, incluindo diretivas de compilação para declarar variáveis compartilhadas e especificar paralelismos.
 - OpenMP: biblioteca para paralelização automatizada de código Fortran e C(++). Usando diretivas inseridas no código, tornou-se um padrão para sistemas com memória compartilhada.

Modelos de programação

Programação com Memória Distribuída (clusters):

- Computação paralela baseada na **passagem de mensagem** (*Message Passing Parallel Programming*)
 - Message-Passing Interface (MPI): padrão

Computação em Grade (Grid Computing):

- Computação paralela baseada na execução de código remotamente
 - Ativação remota de código
 - Web/Grid Services
- Implementação padronizada: **Globus** (OGSI)

Computação em nuvem (Cloud Computing):

- Computação distribuída através de recursos virtualizados, acessíveis via Internet, na forma de serviços
- Usuários não têm conhecimento da tecnologia que provê os serviços
- Conceitos: Infrastructure as a service (IaaS), Platform as a service (PaaS) e Software as a service (SaaS)

Por quê computação paralela?

Demanda por poder computacional é sempre crescente:

- Desejo de resolver **novos** problemas
- Necessidade de resolver problemas computacionais já tratados:
 - com melhor precisão
 - de maneira mais rápida
- Limitação na capacidade de integração de circuitos (tamanho, consumo de energia, dissipação de calor, ...) e de aumento de desempenho com um único chip

Problemas computacionais

Aplicações atuais em muitos casos envolvem a manipulação de **grandes volumes de dados**, o que requer processamento extensivo.

Exemplos:

- Bancos de dados paralelos e *data mining*
- Exploração mineral
- Máquinas de busca na Web
- Serviços baseados na Web
- Suporte para diagnósticos auxiliados por computador
- Gerenciamento de grandes empresas
- Computação gráfica e realidade virtual
- Suporte para tecnologias multimídia
- Ambientes para trabalho cooperativo

Grand Challenge Problems

"A grand challenge problem is one that cannot be solved in a reasonable amount of time with today's computers."

Exemplos (http://en.wikipedia.org/wiki/Grand_Challenge_problem):

- Applied Fluid Dynamics
- Meso- to Macro-Scale Environmental Modeling
- Ecosystem Simulations
- Biomedical Imaging and Biomechanics
- Molecular Biology
- Molecular Design and Process Optimization
- Cognition
- Fundamental Computational Sciences
- Grand-Challenge-Scale Applications
- Nuclear power and weapons simulations

Programação Paralela

Problemas computacionais complexos normalmente apresentam características que favorecem o uso da computação paralela:

- Podem ser **divididos** em partes distintas que podem ser executadas simultaneamente
- Podem ter diversas instruções sendo executadas ao mesmo tempo
- São executados em **menor tempo** quando **múltiplos** recursos computacionais são utilizados

Hélio Crestana Guardia

Programação Paralela

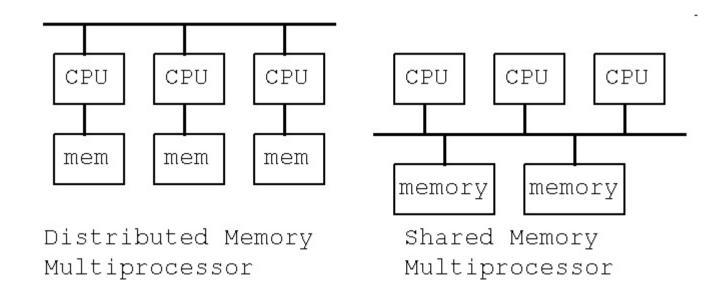
- Programação paralela trata da programação de múltiplos computadores, ou de computadores com múltiplos processadores, para resolver um problema mais rapidamente do que é possível com um único processador.
- Ideia: resolução de um problema normalmente pode ser dividida em tarefas menores, que podem ser executadas simultaneamente com alguma coordenação.
- Motivos:
 - Tratar problemas maiores, que requerem mais **processamento** ou mais **memória** que a normalmente disponível em um único sistema.
 - Prover tolerância a falhas, ...
- **Problema**: *N* computadores trabalhando de maneira simultânea podem obter um resultado *N* vezes mais depressa?

Programação Paralela: etapas

- Decomposição do programa ou dos dados
- Distribuição dos programas ou dados
- Coordenação do processamento e das comunicações
- Aspectos:
 - Arquitetura paralela
 - Formas de comunicação

Tipos de Computadores Paralelos

- Multiprocessadores com memória compartilhada
- Multicomputadores com memória distribuída



Taxonomia de Flynn (*)

Classificação de computadores de alto desempenho, baseada na forma de manipulação de instruções e dados:

- SISD: Single instruction, single data stream
- MISD: Multiple instruction, single data stream
- SIMD: Single instruction, multiple data streams
- MIMD: Multiple instruction, multiple data streams

(*) M.J. Flynn, *Some computer organizations and their effectiveness*, IEEE Transactions on Computing, C-21, (1972) 948-960.

Taxonomia de Flynn

- Single instruction, single data stream (SISD): computador convencional com uma CPU, sem paralelismo de instruções ou dados, como um PC ou um mainframe.
- Multiple instruction, single data stream (MISD): computador hipotético, em que múltiplos processadores atuariam sobre um único fluxo de dados. Pode ser empregado em casos de paralelismo para redundância.

Hélio Crestana Guardia

Taxonomia de Flynn

• Single instruction, multiple data streams (SIMD): computador que explora múltiplos fluxos de dados com um único fluxo de instruções. Normalmente possui grande número de processadores, que executam a mesma operação de maneira coordenada (lock-step) sobre dados diferentes, como um array processor ou vectorprocessor.

Uma variação dessa classificação inclui:

• Single Program, multiple data streams (SPMD): múltiplos processadores autônomos executando simultaneamente o mesmo conjunto de instruções, de maneira independente, sobre dados distintos.

Taxonomia de Flynn

• *Multiple instruction, multiple data streams (MIMD)*: consistem de múltiplos processadores autônomos, que executam diferentes instruções sobre diferentes conjuntos de dados. Exemplos dessa arquitetura incluem os sistemas distribuídos.

Uma sub-divisão desses sistemas pode ser feita em função do compartilhamento de memória:

- **Sistemas com memória compartilhada**: apresentam múltiplas CPUs que compartilham o mesmo espaço de endereçamento, como os sistemas SMP.
- **Sistemas com memória distribuída**: neste caso, cada CPU possui sua própria memória. Redes de comunicação podem permitir trocas de dados, usando diferentes topologias e tecnologias de comunicação, normalmente transparentes para as aplicações.

Aspectos do paralelismo dos processadores

- Acoplamento dos processadores
- Simetria de multiprocessamento
- Multi-Core e Hyper-Threading
- Hierarquias de memória

Hélio Crestana Guardia

Acoplamento dos Processadores

Processor coupling

- Sistemas **fortemente acoplados** (*tightly-coupled*):
 - Múltiplas CPUs conectadas no nível do barramento interno (bus)
 - Acesso a **memória compartilhada** (SMP) ou hierarquia de memória com acesso não uniforme (NUMA).
 - Sistemas *multi-core* são exemplo extremo de acoplamento.
- Sistemas fracamente acoplados (loosely-coupled):
 - *Clusters*, tipicamente, compostos de nós simples ou duais, interligados por rede de comunicação rápida.
 - Mais baratos para serem integrados (agrupados) e atualizados

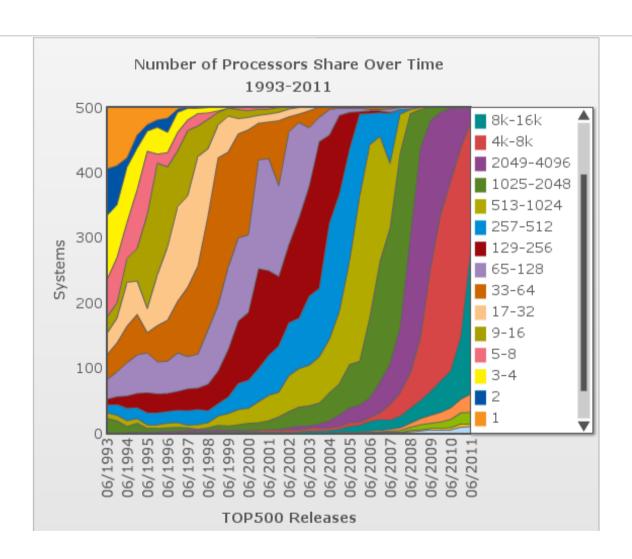
Simetria de Multiprocessamento

- Em um sistema multiprocessado, CPUs podem ter as mesmas funcionalidades ou pode haver funções executadas por apenas algumas delas.
- Questões de *hardware* e do **Sistema Operacional** determinam a **simetria** entre os processadores.
- Tratamento de **interrupções** e a execução de **serviços em** *kernel mode* são exemplos de atividades que podem não ser balanceadas entre todos os processadores disponíveis.
- Simplicidade do modelo assimétrico pode gerar gargalos no desempenho.
- Sistemas em que todas as CPUs são simétricas são chamados *Symetric Multiprocessing* (SMP)
- Em *clusters*, o processamento é tipicamente assimétrico

Computadores: Limites e tendências

- Limitações físicas dificultam criar computadores mais rápidos:
 - **Transmissão de dados**: velocidade do computador depende da taxa de transmissão no *hardware*. Luz: 30 cm/ns; transmissão em cobre: 9 cm/ns. Aumento da velocidade implica diminuir distância entre elementos.
 - Miniaturização: tecnologia de processadores tem permitido aumentar número de transistores em *chip*, mas há limitações sobre quão pequenos componentes podem ser.
 - **Economia**: custo para desenvolver processador mais rápido é cada vez maior.
- Vantagens do paralelismo:
 - Processadores **comerciais** oferecem desempenho cada vez melhor, incluindo múltiplos processadores no mesmo *chip* (*dual-core*, *multi-core*) e suporte para execução simultânea de várias atividades (*Hiper-Threading*).
 - **Redes rápidas**: tecnologias de rede oferecem interligação da ordem de 1 e até 10 Gbps em preços acessíveis para grupos de máquinas.
- Uso de N processadores comuns **interligados** é mais **barato** que 1 processador N vezes mais rápido com **mesmo desempenho**.

Alto desempenho: tendências



http://www.top500.org/lists/2011/06

Sistemas Operacionais 2 Hélio Crestana Guardia

Hyper-Threading

- Hyper-threading (Hyper-Threading Technology HTT) é uma tecnologia Intel para a execução simultânea de tarefas na arquitetura Pentium 4, aprimorando o suporte de threading que surgiu nos processadores Xeon.
- Desempenho do processador é melhorado fazendo com que ele execute processamento útil quando estaria ocioso, como nas falhas de dados em cache (*cache miss*), *branch misprediction*, ou dependência de dados.
- Operação ocorre duplicando as partes específicas do processor relacionadas com a manutenção do *estado do hardware*.

http://www.intel.com/technology/hyperthread

Multi-Core

- Processadores multi-core combinam 2 ou mais processadores independentes em um mesmo Circuito Integrado
- Sistema operacional "enxerga" cada um dos *cores* com um processador distinto, com seus próprios recursos de execução
- Paralelismo no nível de tarefas é facilitado

http://www.intel.com/software/multicore

NUMA: Non-Uniform Memory Access / Architecture

- Arquiteturas NUMA são uma extensão dos sistemas SMP
- *Non-Uniform Memory Access* trata do projeto de acesso à memória em sistemas multiprocessados, utilizando módulos de memória para cada processador
- Técnicas empregadas incluem o uso de *caches* internos ao processador cada vez maiores e algoritmos sofisticados para evitar *cache miss*
- Presença dos dados sendo manipulados nos caches locais favorece o paralelismo nos acessos
- *Hardware* (ou *software*) adicional provê a cópia automática dos dados entre os módulos de memória dos processadores, normalmente por demanda, quando os dados são compartilhados
- A manutenção da consistência dos dados compartilhados nos diversos caches é um problema significativo e um gargalo no desempenho desses sistemas.
- Arquiteturas *Cache-coherent NUMA* (ccNUMA) usam *hardware* especial para manter a consistência dos dados compartilhadosnos *caches*.
- Coerência dos dados é obtida com trocas de informações entre controladores de cache nos processadores quando um mesmo bloco de dados é mantido em vários caches.

Aspectos da programação paralela e concorrente

Granularidade

- É definida pela razão entre computação e comunicação
- **Granularidade Fina** (*fine-grain*) ou paralelismo com alto grau de acoplamento (*tightly coupled parallelism*):
 - Tarefas são relativamente pequenas em termos de código e tempo de execução.
 - Neste caso, há pouca transferência de dados entre as tarefas.
- Granularidade Grossa (coarse grain) ou paralelismo com pequeno grau de acoplamento (loosely coupled):
 - Tarefas relativamente grandes,
 - Comunicação frequente entre as tarefas
- Potencial de paralelização é maior com granularidade fina mas, nesse caso há mais sobrecargas de comunicação e sincronização.

Aspectos da programação paralela e concorrente

Atributos desejáveis de algoritmos e programas paralelos:

- **Concorrência** (*concurrency*): capacidade de executar diversas ações simutaneamente.
- Escalabilidade (*scalability*): capacidade de se adaptar a ambientes com maiores números de processadores (escalabilidade de arquitetura).
- Localidade (*locality*): taxa alta de acessos a dados locais em relação a acessos remotos.
- Modularidade (*modularity*): possibilidade de decomposição em componentes mais simples, desenvolvidos separadamente como módulos independentes, combinados para a realização do programa. Usando interfaces definidas, modificações dos módulos são facilitadas. Projetos modulares reduzem a complexidade dos programas e facilitam a reutilização de código.

Aspectos da programação paralela e concorrente

Localidade

- Acessos à memória local são menos custosos que acessos remotos.
- Operações *read* e *write* são menos onerosas que *send* e *receive*.
- **Localidade** trata da frequência dos acessos locais em oposição aos feitos em *hosts* remotos.
- Assim como concorrência e escalabilidade, **localidade** é um requisito fundamental em programação paralela.
- Importância da localidade é proporcional à relação do custo do acesso remoto sobre os acessos locais.
- Desempenho do computador, da rede utilizada e dos mecanismos de acesso para envio e recebimento de dados pela rede influenciam nessa relação.

Interconexão Física

- Redes de interconexão rápidas são decisivas em sistemas paralelos e *clusters*.
- Escalabilidade de aplicações em *clusters* era limitada pela alta latência das redes *Ethernet*, predominante em muitos cenários.
- Embora (10) *Gigabit Ethernet* seja amplamente utilizado atualmente, com largura de banda teórica de(10x) 125 MB/s, sua aplicação restringe-se aos casos em que a latência dos acessos não é fundamental.
- Outras soluções especializadas e com alto desempenho para interconexão de nós de processamento:
 - Infiniband
 - Myrinet
 - QsNet
 - SCI (Scalable Coherent Interface)

